

Atelier déploiement de pipeline (Hadoop) - Semestre 8

Code	Nb Heures	Titre / Diplôme (fiche RNCP)	Bloc de compétences	Compétences (N°Ref)
DEPE855	14	EID / RNCP 36921	Administration et Supervision d'une plateforme Big Data	EID4.4/EID4.5/EID4.6

Département pédagogique : Direction de l'Innovation et de la Pédagogie

OBJECTIFS & COMPETENCES

Titre / Diplôme préparé

Expert en Ingénierie des données

Bloc de compétences

Numéro 4

Administration et Supervision d'une plateforme Big Data

Compétences à acquérir

[EID4.4](#)

Concevoir un ensemble de tests de surveillance des pipelines afin d'anticiper et d'organiser l'évaluation et le dépannage des représentations de données.

[EID4.5](#)

Administrer la plateforme de stockage de données déployée dans un environnement technologique optimal afin de répondre aux trois critères sinequa non tels que la performance, la capacité et la bande passante de la plateforme.

[EID4.6](#)

Dimensionner en temps réel les besoins en consommation de ressources en mettant en place l'autoscaling des ressources afin d'anticiper les montées en charge et assurer la fiabilité de la solution.

Compétences humaines HEP

Résumé du module

Compétences à acquérir
Déployer et gérer des pipelines de données sur une plateforme Big Data

Approche pédagogique
Atelier

Formule Pédagogique & évaluation
Déroulement (cf maquette pédagogique)

FORMULE PEDAGOGIQUE & EVALUATION

Prérequis recommandés

--

Modules/cours connexes importants

Déroulement (Cf Maquette - en heures)

FFP (HG)	Classe virtuelle (HG)	Suivi collectif (HGPG)	FOAD (TICE)
4	6	4	

Autonomie (Stag)	APP (suivi individuel, ...) (SMEM)	Evaluation (Jury - surv)
		MSPR TP944

Evaluation (Cadre prérempli en fonction des éléments du dossier de certification ou diplôme)

Type	Description	%
Contrôle continu	1 évaluation formative	N.C.
MSPR	Mise en situation professionnelle reconstituée : Administration et supervision d'une plateforme Big Data sécurisée selon les principes agile dans un environnement multiculturel	100
Choisir dans liste		

"Description de l'évaluation"

--

Critères d'évaluation

Adaptation des tiers temps (évaluation finale et contrôle continu)

Si évaluation = examen écrit, merci d'indiquer :

- Documents autorisés
- Dictionnaire bilingue autorisé
- Calculatrice autorisée

PLAN DETAILLE

RECOMMANDATIONS

Le contexte et l'environnement de travail sont à définir par l'intervenant. Les informations données par la suite lui permettent de lister les réalisations à parachever durant cet atelier

INTRODUCTION

Contexte à communiquer aux apprenants :

Vous faites partie d'une équipe chargée de déployer et de gérer des pipelines de données sur une plateforme Big Data dans une entreprise de services financiers. Votre objectif est d'assurer la préparation et la mise à disposition efficace des données aux différentes équipes utilisatrices, telles que les data scientists et l'équipe B.I.

Partie I. Déploiement de pipeline

FFP (HG)	Classe virtuelle (HG)	Suivi collectif (HGPG)	FOAD (TICE)
4	6	4	

Autonomie (Stag)	APP (suivi individuel, ...) (SMEM)	Evaluation (Jury - surv)

Section 1 :

Analyse des besoins des utilisateurs : En tant que membre de l'équipe, vous devez comprendre les besoins spécifiques des data scientists et de l'équipe B.I. Identifiez les types de données requis, les fréquences de mise à jour et les transformations nécessaires.

Conception du pipeline de données : Concevez un pipeline de données qui répond aux besoins identifiés. Déterminez les étapes de prétraitement, de transformation et de chargement nécessaires.

Sélection des outils et des technologies : Choisissez les outils et les technologies adaptés pour implémenter le pipeline de données. Cela peut inclure des frameworks tels que Hadoop, Apache Spark, ou des outils spécifiques de gestion de flux de données.

Configuration du pipeline : Configurez et paramétrez les composants du pipeline de données, tels que les extracteurs, les transformateurs et les chargeurs. Assurez-vous que les données sont collectées, nettoyées, transformées et chargées de manière cohérente et fiable.

Tests du pipeline : Effectuez des tests approfondis pour valider le bon fonctionnement du pipeline de données. Vérifiez l'intégrité des données, la conformité aux règles de transformation et les performances globales du pipeline.

Surveillance et maintenance : Mettez en place des mécanismes de surveillance pour suivre le flux de données à travers le pipeline. Identifiez les problèmes potentiels et effectuez des tâches de maintenance régulières pour assurer la disponibilité continue du pipeline.

Documentation et formation : Documentez le pipeline de données, y compris les étapes, les composants utilisés et les règles de transformation. Fournissez une formation aux utilisateurs finaux sur l'utilisation du pipeline et sur la manière d'accéder aux données préparées.

Améliorations et évolutivité : Identifiez les opportunités d'amélioration du pipeline de données et proposez des modifications ou des ajouts pour répondre aux futurs besoins des utilisateurs. Assurez-vous que le pipeline est évolutif et peut gérer des volumes de données croissants.

Savoirs, savoir-faire et compétences à acquérir dans la section

"Liste des savoirs, savoir-faire et compétences"

BIBLIOGRAPHIE-SITOGGRAPHIE

Lectures recommandées :

J. Chokogoue - Hadoop - Devenez opérationnel dans le monde du big Data - Avril 2017
J Densmore - Data Pipelines Pocket Référence - O'Reilly - Février 2021

Plateformes conseillées :

360 Learning
Linkedin Learning
Bibliothèque ENI